

# **Informe Técnico:**

## **Análisis Multi Algorítmico de Radiografías de Tórax para la Detección de Neumonía**

Integrantes:  
Diego Ortiz  
Cristobal Salcedo  
Esteban Zenteno

## [Resumen Ejecutivo](#)

### [Capítulo 1: Fundamentos Clínicos y Tecnológicos](#)

#### [1.1. La Neumonía desde una Perspectiva Radiológica](#)

#### [1.2. El Desafío de la Visión Computacional en Medicina](#)

### [Capítulo 2: Adquisición, Preprocesamiento y Estructuración de Datos](#)

#### [2.1. Auditoría del Dataset Original](#)

#### [2.2. Estandarización Geométrica y de Color](#)

#### [2.3. El Problema del CSV y la Solución con Pickle](#)

#### [2.4. Consolidación Final del Dataset](#)

### [Capítulo 3: Baseline y Aprendizaje Basado en Instancias \(KNN - Cristóbal\)](#)

#### [3.1. Teoría Matemática de K-Nearest Neighbors](#)

#### [3.2. Implementación y Carga de Datos Estructurada](#)

#### [3.3. Retos de KNN: La Maldición de la Dimensionalidad](#)

### [Capítulo 4: Ensamble de Árboles y Aprendizaje Clásico Avanzado \(Random Forest\)](#)

#### [4.1. Filosofía del Bosque Aleatorio](#)

#### [4.2. Normalización de Invarianza y Profundidad del Ensamble](#)

#### [4.3. Resultados Sorprendentes: El Récord del 97.30%](#)

#### [4.4. Explicabilidad Analítica: Feature Importances](#)

### [Capítulo 5: Deep Learning y Redes Neuronales Convolucionales](#)

#### [5.1. El Paradigma de las CNN en Imágenes Médicas](#)

#### [5.2. Arquitectura CNN Base vs. Transfer Learning \(DenseNet121\)](#)

#### [5.3. Explicabilidad Clínica Visual: La Implementación de Grad-CAM](#)

### [Capítulo 6: Análisis Comparativo Global y Matrices de Evaluación](#)

### [Capítulo 7: Conclusiones, Ética Tecnológica y Horizonte Futuro](#)

#### [7.1. Síntesis de los Hallazgos Científicos](#)

#### [7.2. Advertencias Médicas y Éticas \(Disclaimer Regulatorio\)](#)

# Resumen Ejecutivo

El presente documento constituye un informe técnico de máxima profundidad que detalla los procesos, fundamentos teóricos, implementaciones algorítmicas y resultados obtenidos en el proyecto de clasificación de imágenes médicas "Chest X-Ray Images (Pneumonia)" originado en la plataforma Kaggle. Este proyecto no se limita a la simple aplicación de un algoritmo, sino que establece un estudio comparativo riguroso entre tres paradigmas fundamentales de la Inteligencia Artificial: el aprendizaje basado en instancias mediante K-Nearest Neighbors (KNN), el aprendizaje supervisado mediante ensambles de árboles de decisión (Random Forest), y el estado del arte en visión computacional mediante Redes Neuronales Convolucionales (CNN) y Transfer Learning (DenseNet121) elaborado. A lo largo de este extenso informe, se desglosarán meticulosamente los pipelines de preprocesamiento, la mitigación de la maldición de la dimensionalidad, las métricas de rendimiento y las técnicas de interpretabilidad clínica (Grad-CAM y Feature Importances) necesarias para validar éticamente estos modelos en un entorno biomédico.

# **Capítulo 1: Fundamentos Clínicos y Tecnológicos**

## **1.1. La Neumonía desde una Perspectiva Radiológica**

La neumonía es una afección respiratoria grave caracterizada por la inflamación de los alvéolos pulmonares, los cuales pueden llenarse de fluido purulento, dificultando el intercambio gaseoso. En el ámbito clínico, la radiografía de tórax posterior-anterior (PA) o antero-posterior (AP) es el examen de primera línea para su diagnóstico. En una placa de rayos X, el aire dentro de los pulmones sanos permite que la radiación pase libremente, plasmándose en un color negro (radiolúcido). Por el contrario, la consolidación o el líquido provocado por la neumonía absorbe los rayos, apareciendo como manchas blancas u opacidades (radiopacas) en las bases o lóbulos pulmonares. El desafío para la Inteligencia Artificial radica en distinguir estas opacidades patológicas de estructuras anatómicas normales (costillas, silueta cardíaca, diafragma) o de artefactos externos.

## **1.2. El Desafío de la Visión Computacional en Medicina**

A diferencia de conjuntos de datos clásicos (como imágenes de perros y gatos), las radiografías médicas presentan una alta varianza intra-clase y una baja varianza inter-clase. Esto significa que dos radiografías de pacientes distintos con neumonía pueden verse muy diferentes debido a la anatomía, mientras que una radiografía sana y una enferma pueden verse extremadamente similares a los ojos de un algoritmo no entrenado. Por tanto, el preprocesamiento de la imagen, la normalización de la intensidad de los píxeles y la elección de la arquitectura del modelo predictivo son fases críticas que determinan el éxito o el fracaso absoluto del proyecto.

## **Capítulo 2: Adquisición, Preprocesamiento y Estructuración de Datos**

### **2.1. Auditoría del Dataset Original**

El proyecto comenzó con la descarga y auditoría del dataset de Kaggle, el cual originalmente presentaba imágenes en diversos tamaños, formatos (JPEG, PNG) y, en algunos casos, con diferentes canales de color (algunas en escala de grises, otras almacenadas en RGB de forma redundante). El primer paso del equipo (Trabajo 2 y Zenteno) fue realizar un Análisis Exploratorio de Datos (EDA) visual para identificar y aislar archivos corruptos o dimensiones anómalas que pudieran generar excepciones durante la carga de tensores.

### **2.2. Estandarización Geométrica y de Color**

Para que los algoritmos matemáticos puedan operar comparativamente, todas las matrices de entrada deben tener la misma forma (shape). Se tomó la decisión arquitectónica de convertir todas las imágenes estrictamente a un único canal (escala de grises) y redimensionarlas a matrices exactas de 128 x 128 píxeles. Esta resolución de 128x128 genera un total de 16,384 características (features) por imagen al momento de ser aplanadas. Es un balance óptimo que preserva la textura de los infiltrados pulmonares sin saturar la memoria RAM de los equipos de entrenamiento.

### **2.3. El Problema del CSV y la Solución con Pickle**

Un desafío técnico mayor surgió durante la fase de almacenamiento persistente. Inicialmente, se intentó guardar los datos procesados en formato CSV (Comma-Separated Values). Sin embargo, exportar decenas de miles de vectores de 16,384 dimensiones a texto plano resultó ser catastrófico: el tamaño del archivo explotó a varios gigabytes, y los tiempos de lectura (I/O) eran prohibitivos. La solución implementada fue la migración al formato binario de serialización de Python: .pkl (Pickle). Al usar Pickle, las matrices NumPy nativas mantienen su tipo de dato original

(por ejemplo, enteros sin signo de 8 bits, uint8), logrando una compresión implícita masiva y reduciendo los tiempos de carga a escasos segundos.

## **2.4. Consolidación Final del Dataset**

El archivo serializado final, denominado XrayNeumonia.pkl, consolidó un total de 11,712 registros meticulosamente etiquetados. Esta base de datos limpia quedó compuesta por 8,546 imágenes confirmadas con Neumonía y 3,166 imágenes de pacientes Normales. Este desbalance de clases a favor de la Neumonía fue documentado para ser manejado posteriormente mediante métricas de evaluación rigurosas (como el F1-Score) en lugar de depender únicamente de la exactitud (Accuracy).

# **Capítulo 3: Baseline y Aprendizaje Basado en Instancias (KNN - Cristóbal)**

## **3.1. Teoría Matemática de K-Nearest Neighbors**

El modelo K-Nearest Neighbors (KNN), desarrollado en el notebook de Cristóbal, se utilizó como el modelo fundamental (Baseline) del proyecto. KNN es un algoritmo perezoso (lazy learning); no construye un modelo interno ni ajusta pesos durante el entrenamiento, sino que memoriza el espacio de características. Al recibir una imagen nueva, el algoritmo mide la "distancia" entre el nuevo vector de píxeles y todos los 11,712 vectores en el conjunto de entrenamiento, asignando la etiqueta basándose en el voto mayoritario de sus 'K' vecinos más cercanos.

## **3.2. Implementación y Carga de Datos Estructurada**

El proceso comenzó asegurando la carga segura del entorno. Cristóbal implementó bloques estructurados para la ingesta de los datos serializados:

Una vez en memoria, las matrices 2D de 128x128 fueron "aplanadas" (flattened) a vectores 1D. Esto es un requisito estricto para calcular la métrica de distancia

(típicamente Distancia Euclidiana o Distancia Manhattan) entre los puntos en el hiperespacio de 16,384 dimensiones.

### **3.3. Retos de KNN: La Maldición de la Dimensionalidad**

A pesar de ser un punto de partida excelente para probar la separabilidad lineal de los datos, el enfoque se enfrentó a un problema matemático clásico: "La Maldición de la Dimensionalidad". A medida que el número de píxeles (dimensiones) crece, las distancias entre todos los puntos tienden a converger, diluyendo la diferencia entre el vecino más cercano y el más lejano. Además, el costo computacional en la fase de inferencia es altísimo, ya que cada predicción tiene una complejidad de  $O(N * D)$ , donde  $N$  es el número de imágenes de entrenamiento y  $D$  es 16,384. A pesar de estas limitaciones, KNN logró establecer un umbral de rendimiento inicial que sirvió de parámetro comparativo para los algoritmos más sofisticados.

## **Capítulo 4: Ensamble de Árboles y Aprendizaje Clásico Avanzado (Random Forest)**

### **4.1. Filosofía del Bosque Aleatorio**

Para superar las limitaciones paramétricas de KNN, el Trabajo 2 avanzó hacia la utilización de un meta-estimador de aprendizaje automático altamente sofisticado: Random Forest (Bosque Aleatorio). Esta técnica de ensamble utiliza el concepto de "Bagging" (Bootstrap Aggregating). En lugar de depender de un solo modelo o de la distancia directa, crea cientos de Árboles de Decisión independientes. Cada árbol se entrena sobre una submuestra aleatoria de las imágenes y sobre un subconjunto aleatorio de los píxeles. La predicción final es el resultado de la votación democrática de todos los árboles del bosque.

### **4.2. Normalización de Invarianza y Profundidad del Ensamble**

Antes de la inyección de los datos en el modelo, se aplicó una técnica de invarianza.

Los valores de los píxeles, originalmente en una escala de 0 a 255, fueron normalizados para restringirse estrictamente en un rango flotante desde 0.0 a 1.0. Esta normalización acelera la convergencia y evita que píxeles extremadamente brillantes dominen sesgadamente las particiones de los árboles. El modelo fue configurado para explorar relaciones complejas, permitiendo que los árboles crecieran hasta 20 niveles de profundidad. Este parámetro es crítico: si es muy bajo (ej. 3 niveles), el modelo sufre de *underfitting* y no logra distinguir características médicas sutiles; si es infinito, memoriza el conjunto de entrenamiento. El nivel 20 representó un punto estable metodológico.

### 4.3. Resultados Sorprendentes: El Récord del 97.30%

El Random Forest demostró un poder predictivo formidable al concentrarse efectivamente en las variaciones de intensidad dentro de la cavidad torácica de las radiografías. El modelo fue puesto a prueba frente a un conjunto de evaluación masivo y totalmente oculto durante el entrenamiento, compuesto por 3,514 imágenes. Los resultados documentados fueron los siguientes:

- **Instancias Evaluadas:** 3,514 imágenes.
- **Predicciones Correctas:** 3,419 aciertos.
- **Predicciones Erradas:** 95 equivocaciones.
- **Precisión Global (Accuracy):** 97.30%.


Este desempeño es extraordinario para un algoritmo de Machine Learning clásico aplicado a visión computacional pura, demostrando que la fase previa de ingeniería de datos (redimensión y normalización de la matriz) fue ejecutada a la perfección.

### 4.4. Explicabilidad Analítica: Feature Importances

Uno de los grandes aportes del trabajo fue la interpretabilidad. El modelo Random Forest expone una métrica llamada "Feature Importances" (Importancia de las Características). El equipo pudo extraer qué píxeles específicos fueron los más utilizados por los miles de árboles para tomar decisiones. Al mapear estos píxeles de vuelta a la geometría 2D, se comprobó que el algoritmo ignoraba los bordes negros externos de las imágenes, los cuellos y los brazos de los pacientes, concentrando todo



su poder de decisión analítico precisamente sobre las zonas de las bases pulmonares, donde típicamente se alojan las consolidaciones por neumonía. Para documentar esto de forma presentable, se generaron reportes dinámicos renderizados en HTML.



## Capítulo 5: Deep Learning y Redes Neuronales Convolucionales

### 5.1. El Paradigma de las CNN en Imágenes Médicas

Mientras que KNN y Random Forest requieren el aplanamiento de la imagen (destruyendo la relación espacial 2D entre píxeles vecinos), las Redes Neuronales Convolucionales (CNN), desarrolladas en el análisis, procesan las matrices de píxeles en su forma bidimensional original. Mediante el uso de "filtros convolucionales" que

escanean la imagen de izquierda a derecha y de arriba a abajo, la red es capaz de extraer jerarquías visuales: detecta líneas y bordes en las primeras capas, patrones de texturas y tejidos en las capas medias, y formas anatómicas complejas en las capas profundas. Se estructuraron carpetas rígidas (data, modelos, scripts, figuras).

## 5.2. Arquitectura CNN Base vs. Transfer Learning (DenseNet121)

Se abordó el desafío diseñando y confrontando dos arquitecturas distintas:

- **CNN Base (Diseño Propio):** Una red neuronal diseñada desde cero. Esta arquitectura intercala capas de Convolución 2D con capas de MaxPooling (para reducir la dimensionalidad espacial y retener los rasgos más dominantes) y capas de Dropout (para apagar neuronas aleatoriamente y forzar a la red a no depender de un solo patrón, previniendo el sobreajuste). Al final, las capas Densas convergen en una salida Sigmoide o Softmax para entregar la probabilidad matemática de que la imagen contenga neumonía.
- **Transfer Learning (DenseNet121):** Una red inmensa pre-entrenada con millones de imágenes genéricas (ImageNet). DenseNet tiene la particularidad de que cada capa se conecta directamente con todas las capas posteriores (conexiones densas), facilitando el flujo del gradiente durante el entrenamiento profundo y maximizando la reutilización de características. Esteban adaptó esta red colosal a las radiografías descongelando sus últimas capas de clasificación.

**El hallazgo clave:** Tras iterar en múltiples épocas de entrenamiento (epochs), Zenteno concluyó a través de la métrica F1-Score que la CNN Base propia tenía un rendimiento muy cercano e incluso competitivo frente a DenseNet121. Esto demostró un principio crucial en la ciencia de datos: los modelos masivamente complejos no siempre superan por un margen significativo a modelos más sencillos que han sido entrenados rigurosamente sobre un dataset limpio y específico.

## 5.3. Explicabilidad Clínica Visual: La Implementación de Grad-CAM

En la Inteligencia Artificial médica, el mayor riesgo ético es la "Caja Negra" (Black Box):

algoritmos que arrojan probabilidades de enfermedad sin explicar su razonamiento. Se resolvió este obstáculo magistralmente implementando **Grad-CAM** (Gradient-weighted Class Activation Mapping). Este algoritmo rastrea los gradientes matemáticos retropropagados desde la predicción final hasta la última capa convolucional, calculando qué áreas espaciales de la imagen fueron las responsables directas de la activación neuronal. Posteriormente, este mapa de activación se superpone como un mapa térmico (Heatmap) sobre la radiografía original, las figuras demuestran que en una imagen catalogada como NORMAL, el mapa térmico es difuso o se centra en los bordes del corazón, indicando la ausencia de patologías destacables. Sin embargo, frente a una imagen predicha como PNEUMONIA, Grad-CAM ilumina intensamente (en tonos cálidos) las áreas de los pulmones que presentan infiltrados, derrames o consolidaciones. Esto permite al médico radiólogo corroborar que la decisión de la Inteligencia Artificial se basa en hallazgos anatómico-patológicos reales y no en errores del sistema de rayos X.

# Capítulo 6: Análisis Comparativo Global y Matrices de Evaluación

Para entender la evolución de las soluciones propuestas por el equipo, a continuación se presenta una matriz comparativa profunda de las dimensiones algorítmicas implementadas:

| Criterio de Evaluación     | Cristóbal (KNN)                                 | Trabajo 2 (Random Forest)                                | Esteban Zenteno (CNNs)                                          |
|----------------------------|-------------------------------------------------|----------------------------------------------------------|-----------------------------------------------------------------|
| Naturaleza del Aprendizaje | No paramétrico, basado en instancias.           | Aprendizaje Supervisado (Ensamble / Bagging).            | Deep Learning (Redes Neuronales de Propagación hacia adelante). |
| Transformación de Entrada  | Aplanamiento a vector (1D) de 16,384 elementos. | Vectorización 1D con Normalización estricta (0.0 a 1.0). | Tensores 2D/3D procesados por lotes (Batches) y generadores.    |
| Manejo de                  | Bajo: Sensible a                                | Medio-Alto: Los                                          | Altísimo: Las                                                   |

| Criterio de Evaluación                           | Cristóbal (KNN)                                                | Trabajo 2 (Random Forest)                                               | Esteban Zenteno (CNNs)                                                      |
|--------------------------------------------------|----------------------------------------------------------------|-------------------------------------------------------------------------|-----------------------------------------------------------------------------|
| <b>Variaciones Anatómicas</b>                    | traslaciones o diferencias de tamaño del tórax.                | cientos de árboles mitigan el ruido local.                              | capas convolucionales proveen invarianza traslacional.                      |
| <b>Complejidad Computacional (Entrenamiento)</b> | Prácticamente nulo (solo almacenamiento en RAM).               | Media: Construcción de miles de particiones matemáticas.                | Masiva: Requiere retropropagación de gradientes en GPU/TPU.                 |
| <b>Métricas Demostradas</b>                      | Baseline fundacional de exactitud de separación de datos.      | <b>97.30% Accuracy</b> (3,419 de 3,514 instancias acertadas).           | Altos F1-Scores y curvas de pérdida estabilizadas sin sobreajuste.          |
| <b>Aporte de Interpretabilidad</b>               | Baja. (Distancia directa entre números invisibles al usuario). | Extracción analítica de "Feature Importances" mapeada al área torácica. | Visualización diagnóstica in-situ mediante mapas Grad-CAM.                  |
| <b>Despliegue e Ingeniería</b>                   | Serialización simple mediante Pandas/Pickle.                   | Exportación de Ensamble y creación de reportes estadísticos HTML.       | Prácticas MLOps absolutas: Guardado de modelos, figuras y métricas locales. |

## **Capítulo 7: Conclusiones, Ética Tecnológica y Horizonte Futuro**

### **7.1. Síntesis de los Hallazgos Científicos**

El proyecto integrado abordó el problema de clasificación diagnóstica de la Neumonía mediante tres metodologías escalonadas en complejidad. La base metodológica de limpieza de datos, serialización con Pickle y redimensionamiento de matrices desarrollada en conjunto resultó ser el pilar estructural que permitió el éxito posterior. El modelo KNN operó exitosamente como el grupo de control inicial; el Random Forest demostró que un algoritmo clásico potenciado por un preprocesamiento imputado y normalizado puede rozar la perfección técnica (97.30% de exactitud en pruebas de estrés); y finalmente, el exhaustivo trabajo de Redes Neuronales demostró cómo la inteligencia computacional puede fusionarse con la necesidad médica humana de explicabilidad gráfica, logrando aislar las regiones pulmonares afectadas con asombrosa precisión biomédica mediante Grad-CAM.

## **7.2. Advertencias Médicas y Éticas (Disclaimer Regulatorio)**

Es imperativo señalar. que los alcances logrados en estos tres enfoques.

Las métricas presentadas, por más sobresalientes que sean matemáticamente, no autorizan el uso de estos algoritmos en ambientes hospitalarios vivos. Las herramientas médicas basadas en Inteligencia Artificial deben someterse a estrictos protocolos de regulación (tales como la validación FDA en los Estados Unidos o el marcado CE de dispositivos médicos en Europa). Esto requiere entrenar el modelo no solo con la base de datos controlada de Kaggle, sino con estudios multicéntricos (radiografías de diversas máquinas de diferentes marcas, poblaciones genéticamente diversas, diferentes niveles de ruido radiológico e inclusión de otras patologías confusas como Tuberculosis o Edemas Pulmonares).